Match Facial sem IA no Quarkus

A presente proposta especifica a arquitetura e os fundamentos técnicos para a implementação de um sistema de reconhecimento facial de alta precisão desenvolvido sobre o *framework* Java Quarkus, com persistência e busca vetorial no PostgreSQL via extensão pgvector.

Diferente das abordagens convencionais do mercado baseadas em redes neurais profundas (*Deep Learning*), o sistema foi concebido sob um paradigma 100% determinístico e auditável. O objetivo central é eliminar o comportamento de "caixa-preta" das IAs tradicionais, garantindo transparência matemática irrestrita, rastreabilidade de decisões e estrito cumprimento de requisitos de governança e segurança da informação, sem abrir mão de licenças permissivas e de alto desempenho operacional.

Para atingir a eficiência necessária sem o uso de modelos treinados e outros tipo de IAs, o projeto implementa um *pipeline* sequencial de 5 etapas rigorosas:

1. **Filtro de Qualidade Ambiental (*Quality Gate*)**: Validação matemática de contraste, foco (Laplaciano), iluminação e pose no espaço 3D (Yaw) para eliminação de ruídos na origem.
2. **Filtro de Neutralidade e Estado Fisiológico:** Algoritmos geométricos e de gradiente (Sobel, EAR) para rejeição ativa de expressões faciais, oclusões, boca aberta e piscadelas.
3. **Pré-processamento e Alinhamento:** Ancoragem orbital subpixel, normalização por Transformação Afim 2D, conversão monocromática e equalização CLAHE.
4. **Extração de *Embeddings* Ortogonais**: Geração de 4 descritores complementares que mapeiam formato (HOG), textura de pele (LBP), estrutura holística (PCA/SVD via EJML) e proporções antropométricas (Geométrico), indexados via grafos HNSW no banco de dados.
5. **Decisão por Fusão Ponderada e Cláusula de Veto:** Consolidação dos *scores* via decaimento exponencial na memória do *backend*, aplicando travas de veto individual ($S_i < 0{,}40$) para prevenção do Falso Aceite (FAR).

Com essa abordagem, o sistema alcança uma expectativa de acurácia calibrada entre 97% e 98% em ambientes controlados, entregando uma solução de baixíssima latência, escalável e integralmente explicável.

Etapa 1: Filtro de Qualidade do Ambiente (*Quality Gate*)

Avalia se a fotografia possui condições físicas e ópticas adequadas antes de qualquer processamento. Mais filtros podem ser elencados com implementação em Java.

Validação	**Operação Matemática**	**Critério de Aceitação / Regra**	**Lib / Implementação**
Unicidade Facial	Segmentação no espaço YCbCr + Análise de Componentes Conectados (Blobs).	$N_{\text{rosto}} = 1$ estrito (Rejeita foto sem rosto $N=0$ ou com múltiplos rostos $N > 1$)	BoofCV
Ausência de Oclusão / Objetos	Fração de Pele por Sub-ROIs (YCbCr) + Transformada de Hough para Linhas.	$\text{Fração}_{\text{pele}} \ge 0{,}78$ e sem linhas retas na ROI *(Rejeita máscaras, mãos, celulares ou papéis)*	BoofCV
Nitidez / Foco	Variância do Laplaciano ($\nabla^2 I$) sobre os pixels.	$\text{Variância} \ge 100$ *(Rejeita imagens borradas/tremidas)*	BoofCV
Luminância Média	Média das intensidades dos pixels (μ).	$60 \le \mu \le 200$ *(Rejeita foto sub/superexposta)*	BoofCV
Simetria de Luz	Diferença absoluta da média de brilho dos lados ($\vert{}\mu_L - \mu_R\vert{}$).	Assimetria < 15 *(Rejeita sombras laterais duras)*	BoofCV
Resolução Efetiva	Distância Euclidiana entre as pupilas (IPD).	$IPD \ge 80 \text{ pixels}$ *(Garante densidade amostral)*	BoofCV
Giro da Cabeça	Razão de simetria	Razão ≥ 0.85	BoofCV

(Yaw)	do nariz em relação aos olhos ($\frac{\min(d_L, d_R)}{\max(d_L, d_R)}$).	*(Garante rosto rigorosamente frontal)*	

Em visão computacional determinística, algoritmos como HOG, LBP e PCA dependem da hipótese de que variações na matriz de pixels correspondem a variações na anatomia do rosto. Quando a imagem possui ruídos ópticos (como desfoque, sombras ou superexposição), essa hipótese é violada, gerando falsos vetores de características.

1.Unicidade e Presença Facial (Segmentação YCbCr e Análise de Blobs)

- **Descrição Detalhada:**
  Converte-se a matriz de imagem do espaço RGB para o espaço de cor **YCbCr**, que desacopla a luminância (Y) das componentes de crominância (Cb e Cr). Aplica-se uma limiarização estatística restrita para segmentação de tons de pele humana ($80 \le Cb \le 120$ e $133 \le Cr \le 173$).
  Na máscara binária gerada, realizam-se operações morfológicas (fechamento para preencher lacunas e abertura para eliminar ruídos pontuais) e aplica-se a rotulagem de **Componentes Conectados (*Blob Analysis*)** via BoofCV. Cada *blob* detectado é avaliado quanto a:
    - **Área Mínima:** Deve ocupar no mínimo 10% da área total do quadro.
    - **Razão de Aspecto do Retângulo Delimitador:** $1{,}1 \le \frac{\text{Altura}}{\text{Largura}} \le 1{,}6$ (proporção típica de uma cabeça humana).
- O sistema contabiliza o número de *blobs* (N_{rosto}) que atendem simultaneamente a esses critérios geométricos.
- **Motivação Técnica:**
  - **Prevenção de Ambiguidade de Busca:** Se houver duas ou mais pessoas na foto (ex: alguém passando ao fundo na catraca), os métodos determinísticos de ancoragem da Etapa 3 falhariam ao selecionar os pontos dos olhos, correndo o risco de gerar um *embedding* "híbrido" ou do indivíduo errado.
  - **Proteção contra Ilusões / Cartazes de Fundo:** Elimina erros decorrentes de fundos poluídos (como um quadro, outdoor ou tela de TV no fundo com rostos secundários).
  - **Fail-Fast (Rejeição Rápida):** Se o usuário não estiver enquadrado ($N_{\text{rosto}} = 0$), o sistema encerra o processamento na primeira instrução em milissegundos, economizando ciclos de CPU sem disparar as etapas matemáticas pesadas.

2. 4 Técnicas Determinísticas para Detectar Objetos e Oclusões

1. Fração de Densidade de Pele na ROI (Skin Fraction Analysis)

- **Operação:** Transforma a região delimitada do rosto (ROI) para o espaço de cor YCbCr/HSV e aplica a máscara de limiarização de pele. Calcula-se a proporção de pixels de pele em relação à área total do elipse facial: $$\text{Fração}_{\text{pele}} = \frac{\sum \text{Pixels de Pele na ROI}}{\text{Área da ROI Facial}}$$
- **Regra de Rejeição:** Em um rosto descoberto, a taxa de pele ocupa $> 80\%$ do elipse. Se a pessoa estiver usando máscara, segurando um celular ou cobrindo a face com a mão/papel, a fração despenca. Se $\text{Fração}_{\text{pele}} < 0{,}78$, a foto é **rejeitada por oclusão/objeto**.

2. Validação por Sub-ROIs (Quadrantes Anatômicos)

- **Operação:** A ROI facial alinhada é dividida em 5 sub-regiões fixas: (1) Olho Esquerdo, (2) Olho Direito, (3) Nariz/Centro, (4) Bochechas e (5) Boca/Queixo. A densidade de pele e a variância de iluminação são calculadas para cada sub-região isoladamente.
- **Regra de Rejeição:** Se o usuário usa uma máscara ou segura um copo na boca, a sub-região (5) perde o padrão de pele e a textura de boca. Se **qualquer uma** das 5 sub-ROIs apresentar taxa de pele $< 60\%$, o sistema identifica oclusão localizada (ex: "Objeto cobrindo o terço inferior do rosto").

3. Integridade das Âncoras Anatômicas (Landmark Verification)

- **Operação:** O algoritmo tenta validar sequencialmente a presença dos 4 conjuntos de pontos críticos: pupilas, ponta do nariz e os dois cantos da boca (usando mapas de gradiente e filtros de Shi-Tomasi/Hough).
- **Regra de Rejeição:** Objetos que cobrem partes do rosto impedem o cálculo de gradientes característicos dessas estruturas. Se o detector de pupila, nariz ou lábio falhar em retornar coordenadas válidas com confiança mínima, a foto é **rejeitada por oclusão de feições anatômicas**.

4. Detecção de Bordas Retas Artificiais (Transformada de Hough para Linhas)

- **Operação:** O rosto humano é composto por contornos suaves e curvos. Objetos rígidos (celulares, cartões, papéis, hastes de óculos escuros) introduzem segmentos de linhas retas perfeitas. Aplica-se a **Transformada de Hough para Linhas** na matriz de gradiente (Sobel) dentro da ROI facial.
- **Regra de Rejeição:** Se forem detectados segmentos de retas contínuas com comprimento $L > 0{,}25 \cdot \text{Largura}_{\text{rosto}}$ cruzando a região interna da face, a imagem é **rejeitada por presença de objeto rígido**.

3. Nitidez e Foco (Variância do Laplaciano)

- Descrição Detalhada:
  Aplica-se o operador diferencial de segunda ordem conhecido como Laplaciano ($\nabla^2 I$) sobre a matriz de intensidade de cinza da imagem. O Laplaciano mede a taxa de variação rápida de intensidade (que define bordas afiadas). Em seguida, calcula-se a variância estatística (σ^2) dos valores resultantes de toda a matriz.
  $$\nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$
- Motivação Técnica:
  Imagens borradas ou fora de foco atuam como um filtro passa-baixas (suavização), destruindo transições de alto contraste. Como o descritor HOG depende dos gradientes locais (∇I) para construir seus histogramas de orientação, o desfoque "achata" a magnitude desses gradientes. Uma imagem com variância laplaciana baixa ($\sigma^2 < 100$) gerará um vetor HOG artificialmente homogêneo e sem discriminabilidade.

4. Luminância Média (Análise de Histograma)

- Descrição Detalhada:
  Calcula-se a média aritmética (μ) do valor de intensidade de todos os pixels pertencentes à região limitada do rosto no espaço de cores em escala de cinza ($0 = \text{Preto absoluto}$, $255 = \text{Branco absoluto}$).
  $$\mu = \frac{1}{N} \sum_{x,y} I(x,y)$$
- Motivação Técnica:
  - Subexposição ($\mu < 60$): Em fotos muito escuras, a maioria dos pixels fica compactada na faixa inferior do histograma. A informação de textura do LBP é perdida por falta de dinâmica nos bits (ruído de sensor/quantização predomina).
  - Superexposição ($\mu > 200$): Em fotos muito claras ("estouradas"), ocorre saturação do sensor, onde múltiplos pixels atingem o valor 255. Isso destrói permanentemente as derivadas parciais e o relevo facial.
    O CLAHE (Equalização de Histograma) atua na Etapa 3, mas ele não consegue recuperar informação perdida por saturação ou escuridão extrema; por isso, a rejeição deve ocorrer antes.

5. Simetria de Iluminação (Luz Lateral)

- Descrição Detalhada:
  O retângulo delimitador do rosto é dividido ao meio por uma linha vertical, gerando a submatriz Esquerda (L) e a submatriz Direita (R). Calcula-se a diferença absoluta entre a média de intensidade de ambos os lados:
  $$\Delta_{\text{luz}} = \vert{}\mu_L - \mu_R\vert{}$$
- Motivação Técnica:
  Fontes de luz direcionais (como uma lâmpada ao lado do rosto ou uma janela) criam sombras duras em apenas uma metade da face. Para o algoritmo PCA (Eigenfaces), que opera diretamente nos valores brutos dos pixels e autovetores, uma sombra lateral

é interpretada como uma característica anatômica assimétrica permanente. Além disso, o LBP gera micro-padrões binários completamente diferentes no lado sombreado versus no lado iluminado, destruindo a comparação do histograma global.

6. Resolução Efetiva (Distância Interpupilar - IPD)

- Descrição Detalhada:
  Calcula-se a distância em pixels no espaço 2D (L_2) entre o centro da pupila do olho esquerdo (x_1, y_1) e do olho direito (x_2, y_2):
  $$\text{IPD} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$
- Motivação Técnica:
  A resolução total da imagem (ex: 1920×1080) não garante que o rosto possua informação suficiente se a pessoa estiver longe da câmera. Os descritores clássicos exigem uma densidade mínima de amostragem: para extrair células HOG de 8×8 pixels ou calcular o LBP com raio $R=1$, o rosto precisa cobrir um número mínimo de pixels. Um $\text{IPD} < 80 \text{ pixels}$ significa que o rosto reconstruído na Etapa 3 terá pouca informação geométrica, sofrendo com serrilhamento (*aliasing*) na interpolação.

7. Giro da Cabeça no Eixo Tridimensional (Pose / Yaw)

- Descrição Detalhada:
  Localiza-se a coordenada x da ponta/centro do nariz (x_{nariz}) e mede-se a distância horizontal em relação ao olho esquerdo ($d_L = \vert{}x_{\text{nariz}} - x_1\vert{}$) e ao olho direito ($d_R = \vert{}x_{\text{nariz}} - x_2\vert{}$). Calcula-se a razão de simetria:
  $$\text{Razão}_{\text{Yaw}} = \frac{\min(d_L, d_R)}{\max(d_L, d_R)}$$
- Motivação Técnica:
  A Transformação Afim (Etapa 3) corrige apenas rotações no plano da imagem (2D Roll: inclinação para os lados). Ela não consegue corrigir o giro 3D (Yaw: olhar para a esquerda/direita). Se o rosto estiver girado, ocorre uma deformação perspectiva não linear: um lado da face encolhe horizontalmente e o outro expande. Isso altera a posição relativa das células no HOG e as distâncias do vetor Geométrico. A regra $\text{Razão}_{\text{Yaw}} \ge 0.85$ garante que o rosto esteja estritamente de frente ($\pm 5^\circ$ de tolerância).

Etapa 2: Filtro de Neutralidade Facial e Estado Fisiológico

Valida se o usuário está com expressão neutra e com a região ocular/bucal apta para extração de vetores.

Validação	Operação Matemática	Critério de Aceitação / Regra	Lib / Implementação
Olhos Fechados / Piscadela	Razão de Aspecto do Olho ($\text{EAR} = \frac{\Vert{}p_2 - p_6\Vert{} + \Vert{}p_3 - p_5\Vert{}}{2 \Vert{}p_1 - p_4\Vert{}}$) e Acumulador de Hough.	$\text{EAR} \ge 0.20$ e Acumulador $\ge T_{\text{hough}}$ *(Rejeita pálpebras fechadas/piscadelas)*	BoofCV / Geometria
Abertura da Boca	Razão entre altura e largura da boca ($\frac{H_{\text{boca}}}{W_{\text{boca}}}$).	Razão < 0.22 *(Rejeita boca aberta / sorrisos)*	BoofCV / Geometria
Rugas de Expressão	Densidade de gradientes (Sobel) no sulco nasolabial e testa.	Densidade $<$ Limiar T *(Rejeita franzidos e sorrisos)*	BoofCV
Simetria Labial	Ângulo da linha dos lábios em relação à linha dos olhos (θ_{boca}).	$\vert{}\theta_{\text{boca}}\vert{} \le 3.5^\circ$ *(Rejeita sorrisos assimétricos)*	Trigonometria
Posição Sobrancelhas	Distância vertical olhos-sobrancelha normalizada pelo	Variação $\le \pm 15\%$ *(Rejeita surpresa ou raiva)*	Geometria Analítica

	IPD.		

Filtro de Neutralidade Facial e Estado Fisiológico atua como o segundo portão de qualidade (*Gatekeeper*), focando não na óptica do ambiente, mas na geometria dinâmica do objeto (o rosto).
Em modelos determinísticos (HOG, LBP, PCA e Análise Geométrica), a suposição fundamental é que a topologia facial do usuário no momento do teste é idêntica à foto cadastrada no banco. Expressões faciais, piscar de olhos ou tiques alteram a posição dos tecidos moles e criam rugas temporárias, deformando a matriz de gradientes e destruindo a acurácia dos algoritmos.
1. Olhos Fechados / Piscadela (Razão de Aspecto do Olho - EAR e Hough)

- Descrição Detalhada:
  Mede-se a abertura palpebral através da Razão de Aspecto do Olho (Eye Aspect Ratio - EAR), calculada a partir dos pontos anatômicos das pálpebras superior e inferior (p_2, p_3, p_5, p_6) em relação aos cantos lateral e medial (p_1, p_4):
  $$\text{EAR} = \frac{\Vert{}p_2 - p_6\Vert{} + \Vert{}p_3 - p_5\Vert{}}{2 \Vert{}p_1 - p_4\Vert{}}$$
  Em paralelo, a Transformada de Hough para Círculos avalia a intensidade do acumulador no raio correspondente à íris.
- Motivação Técnica:
  - Falha no Alinhamento Afim: A Etapa 3 usa o centro da íris/pupila como ponto de ancoragem para rotacionar e escalar a imagem. Se a pessoa estiver piscando, o centroide é deslocado para a pálpebra, causando uma rotação totalmente errada na imagem final.
  - Distorção de Gradientes: A região dos olhos é uma das áreas com maior densidade de informação no HOG e no LBP. Pálpebras cobertas criam padrões de textura completamente diferentes de um olho aberto com esclera e íris visíveis, resultando em distâncias altas de vetor no pgvector.

2. Abertura da Boca (Aspect Ratio da Boca)

- Descrição Detalhada:
  Calcula-se a razão entre a distância vertical entre o centro do lábio superior e o centro do lábio inferior (H_{boca}) e a distância horizontal entre os cantos esquerdo e direito da boca (W_{boca}):
  $$\text{Razão}_{\text{boca}} = \frac{H_{\text{boca}}}{W_{\text{boca}}}$$
- Motivação Técnica:
  Sorrisos abertos, gargalhadas ou conversas durante a captura alteram drasticamente a geometria do terço inferior da face:
  - O queixo se desloca para baixo, aumentando a altura vertical do rosto recortado.
  - O PCA (Eigenfaces) é extremamente sensível à abertura da boca, pois a cava oral escura (pixels pretos no centro) altera radicalmente a projeção nos autovetores principais.
  - O Vetor Geométrico perde a proporcionalidade (as razões de distância da boca

até o nariz e queixo saem do padrão). A regra $\text{Razão}_{\text{boca}} < 0.22$ garante lábios selados ou em repouso.

3. Rugas de Expressão (Densidade de Gradientes com Sobel)
    - Descrição Detalhada:
      Aplica-se o Operador de Sobel ($\nabla I = \left[\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y} \right]$) para extrair a magnitude do gradiente ($G = \sqrt{G_x^2 + G_y^2}$) apenas em duas Regiões de Interesse (ROIs) específicas: a *Região Interciliar* (entre as sobrancelhas) e os *Sulcos Nasolabiais* (linhas do nariz ao canto da boca). Calcula-se a densidade média de bordas nessas ROIs.
    - Motivação Técnica:
      Expressões como franzir a testa (raiva/foco) ou sorrir (mesmo com a boca fechada) criam rugas temporárias na pele (vincos mecânicos). Para o LBP (Local Binary Patterns), que analisa pequenos blocos 3×3 de pixels, essas rugas são interpretadas como micro-texturas profundas e permanentes da pele. O filtro rejeita a foto se a densidade de gradientes nessas áreas neutras ultrapassar o limiar limpo T, impedindo a criação de vetores LBP "poluídos".
4. Simetria Labial (Ângulo de Inclinção dos Lábios)
    - Descrição Detalhada:
      Identifica-se a coordenada do canto esquerdo da boca $C_1(x_1, y_1)$ e do canto direito $C_2(x_2, y_2)$. Calcula-se o ângulo da linha dos lábios (θ_{boca}) em relação à linha horizontal dos olhos previamente alinhada ($\theta_{\text{olhos}} = 0^\circ$):
      $$\theta_{\text{boca}} = \arctan2(y_2 - y_1, x_2 - x_1)$$
    - Motivação Técnica:
      Sorrisos irônicos, debochados ou expressões de dúvida elevam apenas um dos lados da boca (sorriso assimétrico). Isso não é pego pela abertura simples da boca, mas quebra a simetria bilateral do HOG. As células do HOG do lado esquerdo do rosto deixam de ser o espelho das células do lado direito, deformando o vetor global do formato facial. Uma tolerância máxima de $\vert{}\theta_{\text{boca}}\vert{} \le 3.5^\circ$ garante simetria.
5. Posição das Sobrancelhas (Índice de Elevação Palpebral)
    - Descrição Detalhada:
      Calcula-se a distância vertical média entre o centro de cada pupila e o ponto médio do arco da sobrancelha correspondente ($D_{\text{sobrancelha}}$), normalizada dividindo pelo valor da Distância Interpupilar (IPD):
      $$\text{Índice}_{\text{sobrancelha}} = \frac{D_{\text{sobrancelha}}}{IPD}$$
    - Motivação Técnica:
      Expressões de surpresa/espanto elevam as sobrancelhas para cima, enquanto expressões de raiva ou dor as abaixam em direção aos olhos. Essa movimentação altera o Vetor Geométrico e desfaz a sobreposição de pixels no PCA (Eigenfaces) da região frontal superior. Manter a variação em uma faixa de $\pm 15\%$ em relação ao valor de repouso anatômico garante que a fronte permaneça totalmente relaxada.

Etapa 3: Pré-processamento e Alinhamento

Normaliza a geometria e a iluminação para padronização matricial estrita.

Operação	Descrição Matemática	Lib / Implementação
Detecção dos Olhos	Localização das pupilas via Transformada de Hough para círculos.	BoofCV
Transformação Afim	Rotação pelo ângulo θ e escala para nivelar e fixar a distância dos olhos.	BoofCV
Recorte e Resize	Crop da região facial e redimensionamento bilinear para 128×128 pixels. OU 160 px?	BoofCV
Conversão Grayscale	Redução da matriz RGB para canal único de luminância (0 a 255).	BoofCV
Equalização CLAHE	Histograma local para suavização e padronização do contraste.	BoofCV

Pré-processamento e Alinhamento é o coração da padronização matricial do arcabouço. Enquanto as Etapas 1 e 2 rejeitam dados inadequados, a Etapa 3 pega a imagem aprovada e a transforma em um espaço vetorial perfeitamente alinhado, recortado e normalizado.
Em métodos determinísticos e algébricos (HOG, LBP, PCA e Geométrico), o algoritmo não possui invariância espacial nativa. Isso significa que se o rosto estiver 2 cm deslocado para o lado ou 5° inclinado, o produto escalar do PCA falhará e as células do HOG serão comparadas com as regiões erradas da face.
1. Detecção Precisa dos Olhos (Localização do Centroide Orbital)

- Descrição Detalhada:
  Aplica-se a Transformada de Hough para Círculos (FactoryDetectCircle do BoofCV) combinada com a busca por mínimos locais na matriz de intensidade (Análise de Perfil

de Projeção / Vales de Luminância) na região superior do rosto. O algoritmo identifica com precisão subpixel o centroide da pupila/íris para o olho esquerdo (x_1, y_1) e para o olho direito (x_2, y_2).

- Motivação Técnica:
  Todo o alinhamento geométrico do sistema depende da ancoragem em pontos anatômicos invariantes. A pupila é a estrutura mais estável e de mais alto contraste do rosto. Sem uma detecção exata do ponto central dos olhos com precisão subpixel, a Transformação Afim subsequente acumulará erros de arredondamento, desalinhando todas as etapas seguintes.

2. Transformação Afim 2D (Nivelamento e Escala)

- Descrição Detalhada:
  Aplica-se uma matriz de transformação geométrica 2D (M) que executa simultaneamente três operações: rotação pelo ângulo de inclinação (θ), redimensionamento pelo fator de escala (s) e conversão translacional para coordenadas fixas target ($x_{\text{alvo}}, y_{\text{alvo}}$):
  $$\theta = \arctan2(y_2 - y_1, x_2 - x_1), \quad s = \frac{D_{\text{alvo}}}{\sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}}$$
  $$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} s \cos\theta & s \sin\theta \\ -s \sin\theta & s \cos\theta \end{bmatrix} \begin{bmatrix} x - x_{\text{centro}} \\ y - y_{\text{centro}} \end{bmatrix} + \begin{bmatrix} x_{\text{alvo}} \\ y_{\text{alvo}} \end{bmatrix}$$
- Motivação Técnica:
  Garante a invariância à rotação e escala.
  - No PCA (Eigenfaces), se os olhos não estiverem exatamente nos mesmos pixels em todas as imagens (ex: pixel $(32, 45)$ e $(96, 45)$), a multiplicação matricial pelos autovetores perde completamente o sentido geométrico.
  - No HOG, as células rígidas de gradiente (ex: 8×8 pixels) precisam cobrir exatamente as mesmas estruturas faciais em todas as fotos cadastradas e buscadas.

3. Recorte e Redimensionamento (Crop e Resize Matriz Fixa)

- Descrição Detalhada:
  A partir das coordenadas fixadas dos olhos, realiza-se o *Crop* (corte) do retângulo delimitador do rosto (remover orelhas, fundo e topo do cabelo) e faz-se o *Resize* da submatriz para uma dimensão fixa estrita de 128×128 pixels utilizando Interpolação Bilinear.
- Motivação Técnica:
  Garante a invariância ao tamanho da imagem original e remoção de ruídos de fundo.
  - Fundos da foto (paredes, móveis) ou cabelos volumosos criam gradientes fortes nas bordas que alteram drasticamente o vetor HOG se não forem cortados.
  - A álgebra linear (EJML para PCA) exige que todas as imagens do sistema sejam vetores de entrada de tamanho idêntico ($128 \times 128 = 16.384$ dimensões brutas). A interpolação bilinear garante suavidade sem introduzir os artefatos de

serrilhamento do vizinho mais próximo.

4. Conversão para Grayscale (Matriz 2D de Luminância)
    - Descrição Detalhada:
      Converte-se a matriz de imagem RGB (3 canais: Vermelho, Verde e Azul) em uma única matriz 2D de intensidade de cinza (I) usando a média ponderada de luminância padronizada (ITU-R BT.601):
      $$I(x,y) = 0.299R + 0.587G + 0.114B$$
    - Motivação Técnica:
      Garante a invariância à cor e redução de dimensionalidade.
      A cor da pele ou balanço de branco da câmera (luz quente vs. luz fria) adiciona ruído espectral irrelevante para a estrutura da face. Além disso, reduz os dados em 3 vezes (de $128 \times 128 \times 3$ para $128 \times 128 \times 1$), permitindo que o BoofCV e o EJML calculem gradientes e matrizes de covariância com altíssima performance em Java.
5. Equalização de Histograma Local (CLAHE)
    - Descrição Detalhada:
      Aplica-se o algoritmo CLAHE (Contrast Limited Adaptive Histogram Equalization). A imagem 128×128 é dividida em pequenas seções não sobrepostas (ex: blocos de 8×8), onde o histograma de contraste de cada região é equalizado individualmente, limitando a amplificação de ruído por um limiar de corte (*clip limit*).
    - Motivação Técnica:
      Garante a invariância a variações suaves e não uniformes de iluminação.
      Diferente da equalização de histograma global (que estoura áreas claras se houver fundo escuro), o CLAHE atua localmente: ele clareia sombras suaves abaixo do nariz ou sob os olhos sem estourar as bochechas. Isso normaliza a resposta de textura do LBP e estabiliza a magnitude do gradiente no HOG, fazendo com que uma foto tirada sob luz fraca e outra sob luz forte gerem vetores idênticos após a equalização.

Etapa 4: Extração dos Embeddings e Armazenamento

Geração dos 4 vetores numéricos e indexação no banco de dados.

Vetor	Descrição / Operação Matemática	Métrica de Distância	Lib / Mapeamento
Vetor HOG	Gradientes espaciais orientados (∇I) agrupados por células.	Distância Euclidiana (L_2)	BoofCV $\rightarrow$ vector(1764)
Vetor LBP	Histograma de padrões binários locais baseados em 8 vizinhos.	Distância Manhattan (L_1)	BoofCV $\rightarrow$ vector(256)
Vetor PCA	Projeção em autovetores via SVD ($A = U \Sigma V^T$).	Distância Euclidiana (L_2)	EJML $\rightarrow$ vector(50)
Vetor Geométrico	Razões e distâncias Euclidianas entre cantos (Shi-Tomasi).	Distância Euclidiana (L_2)	BoofCV $\rightarrow$ vector(16)
Indexação de Banco	Criação de grafos de busca de alta performance no PostgreSQL.	Operadores do pgvector	Índice HNSW no PostgreSQL

Extração dos Embeddings e Armazenamento é a fase na qual a matriz de pixels pré-processada (128×128) é traduzida em descritores numéricos compactos e determinísticos.
Em vez de comparar a imagem inteira pixel a pixel — o que seria computacionalmente inviável e altamente sensível a pequenos ruídos —, extraem-se quatro vetores complementares que representam propriedades matemáticas distintas da face. Esses vetores são padronizados e salvos no PostgreSQL para permitir buscas indexadas de alta performance via pgvector.

1. Vetor HOG (Histogram of Oriented Gradients)
    - Descrição Detalhada:
      A imagem é dividida em pequenas células conectadas (ex: 8×8 pixels). Para cada pixel da célula, calcula-se a magnitude e a direção do gradiente de luminância ($\nabla I = [\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y}]$). As direções dos gradientes são agrupadas em histogramas orientados (geralmente 9 intervalos de 0° a 180°). Os blocos de células são normalizados localmente, gerando um vetor denso final de 1.764 dimensões (vector(1764)).
    - Motivação Técnica:
      Garante a captura da estrutura geométrica e contornos do rosto.
      O HOG é extremamente robusto para mapear as formas anatômicas gerais (curvatura do queixo, formato dos olhos, contorno do nariz e sobrancelhas). Como ele analisa a *orientação das bordas* e não a intensidade direta da luz, ele mantém a invariância quando ocorrem pequenas mudanças na iluminação global.
2. Vetor LBP (Local Binary Patterns)
    - Descrição Detalhada:
      Para cada pixel da imagem, compara-se o seu valor de cinza com o de seus 8 vizinhos imediatos (3×3). Se o valor do vizinho for maior ou igual ao central, atribui-se o bit 1; caso contrário, 0. Essa sequência de 8 bits gera um número decimal (0 a 255). A imagem é dividida em regiões e calcula-se o histograma dessas frequências de padrões, gerando um vetor de 256 dimensões (vector(256)).
    - Motivação Técnica:
      Garante a captura da micro-textura da pele e detalhes locais.
      Enquanto o HOG foca no "esqueleto/formato", o LBP foca nos "detalhes microscópicos" da textura facial (poros, pequenas rugas fixas, transições suaves de pele e variações locais). O LBP é monótono-invariante ao brilho: se todos os pixels de uma região aumentarem de brilho proporcionalmente, os bits mantêm-se rigorosamente idênticos.
3. Vetor PCA (Eigenfaces via Decomposição SVD)
    - Descrição Detalhada:
      A matriz de imagem 128×128 é achatada em um vetor $1D$ de 16.384 dimensões. Esse vetor é projetado sobre uma matriz de base ortogonal composta pelos autovetores principais (obtenção da covariância via Decomposição em Valores Singulares - SVD em EJML). Essa projeção reduz a imagem a um vetor compacto de apenas 50 dimensões (vector(50)).
    - Motivação Técnica:
      Garante a captura da estrutura global holística da face.
      Diferente de HOG e LBP (que trabalham com janelas locais), o PCA analisa a imagem de forma global. Ele decompõe a face em combinações lineares de "rostos fantasmas" (Eigenfaces) que representam a variação estatística máxima do banco de dados. Ele serve como um excelente validador de simetria estrutural ampla do rosto.
4. Vetor Geométrico (Métricas Antropométricas Diretas)
    - Descrição Detalhada:

Utiliza-se o algoritmo de detecção de cantos de Shi-Tomasi/Harris no BoofCV para localizar pontos ancôras anatômicos (cantos dos olhos, ponta do nariz, cantos da boca e queixo). A partir dessas coordenadas, calcula-se um vetor de 16 dimensões (vector(16)) contendo apenas razões e distâncias Euclidianas normalizadas pela Distância Interpupilar (IPD).

- Motivação Técnica:
  Garante invariância espacial pura e validação de proporção anatômica.
  Independente de textura ou iluminação, as proporções do crânio humano (ex: razão entre a distância dos olhos e a distância do nariz ao queixo) são assinaturas geométricas únicas. Este vetor atua como uma "régua seca": ele não analisa pixels ou intensidade de iluminação, apenas a matemática das distâncias anatômicas.

5. Indexação e Armazenamento no PostgreSQL (Índice HNSW)

- Descrição Detalhada:
  Os 4 vetores extraídos são gravados em colunas do tipo vector na tabela do PostgreSQL (pgvector). Para cada coluna de vetor (especialmente HOG e LBP), cria-se um índice HNSW (Hierarchical Navigable Small World) configurado com a métrica de distância adequada (L_2 para HOG/PCA/Geom e L_1 para LBP).
- Motivação Técnica:
  Garante busca vetorial em tempo sub-milissegundo no banco de dados.
  Em vez de realizar uma busca exaustiva (comparar a imagem buscada contra todas as milhões de fotos do banco uma a uma, o que seria impraticável), o índice HNSW constrói um grafo de aproximação multicamadas. Isso permite que a consulta SQL retorne os Top-50 candidatos mais próximos em questão de poucos milissegundos no Quarkus, preparando os dados para a validação final da Etapa 5.

Etapa 5: Lógica de Match e Veto Ponderado

Processamento no backend em Java/Quarkus para decisão final sobre o candidato.

Passo	Operação / Regra	Fórmula / Condição	Implementação / Peso (wi)
1. Pré-seleção	Busca dos Top-K candidatos no PostgreSQL usando o vetor HOG como filtro primário.	ORDER BY vec_hog <-> :busca LIMIT 50	Quarkus pgvector
2. Normalização	Conversão de cada distância bruta (D_i) em score de similaridade padronizado ($[0.0, 1.0]$).	$S_i = e^{-\lambda_i D_i}$	Código Java
3. Ponderação HOG	Atribuição de peso para a similaridade de bordas e gradientes.	$S_{\text{HOG_weighted}} = S_{\text{HOG}} \cdot 0.35$	Código Java ($w = 0.35$)
4. Ponderação LBP	Atribuição de peso para a similaridade de textura de pele.	$S_{\text{LBP_weighted}} = S_{\text{LBP}} \cdot 0.35$	Código Java ($w = 0.35$)
5. Ponderação PCA	Atribuição de peso para a similaridade da estrutura global.	$S_{\text{PCA_weighted}} = S_{\text{PCA}} \cdot 0.15$	Código Java ($w = 0.15$)
6. Ponderação Geomi	Atribuição de peso para as proporções anatômicas.	$S_{\text{Geom_weighted}} = S_{\text{Geom}} \cdot 0.15$	Código Java ($w = 0.15$)

7. Cláusula de Veto	Bloqueio imediato se qualquer vetor individual apresentar discrepância crítica.	**Se qualquer $S_i < 0.40$ $\rightarrow$ REJEITA**	Código Java
8. Fusão Final	Soma dos scores ponderados para decisão da identidade.	$S_{\text{total}} = \sum (S_i \cdot w_i)$	**Decisão:** $S_{\text{total}} \ge 0.78$

Lógica de Match e Veto Ponderado é a camada decisória final do pipeline. Executada inteiramente na memória do backend Java/Quarkus, ela recebe os candidatos pré-selecionados pelo PostgreSQL e consolida as métricas dos 4 vetores independentes em um **score global de similaridade único, determinístico e auditável**.

O maior desafio dessa etapa é unir quatro abordagens matemáticas completamente distintas (espacial, textural, algébrica e geométrica) sem permitir que a dominância de uma métrica esconda uma fraude ou inconsistência apontada por outra.

1. Pré-seleção de Candidatos no PostgreSQL (Top-K Filtering)

- **Descrição Detalhada:**
  Executa-se uma consulta SQL via pgvector utilizando a métrica de Distância Euclidiana (L_2) no índice HNSW da coluna do **Vetor HOG**. A consulta recupera os $K=50$ candidatos com menor distância espacial em relação à imagem de busca:

```
SELECT id, vec_hog, vec_lbp, vec_pca, vec_geom FROM usuarios_face ORDER BY vec_hog <-> :veto_hog_busca LIMIT 50;
```

- **Motivação Técnica:**
  Garante **escalabilidade e eficiência computacional**.
  A fusão ponderada de 4 vetores e a aplicação de funções exponenciais em Java consomem tempo de CPU. Realizar esse cálculo contra um banco de milhões de registros causaria gargalo de I/O e latência inaceitável no Quarkus. Como o HOG é o descritor mais estável para capturar a estrutura geral da face, ele funciona como um "filtro de afunilamento": descarta 99,9% da base em milissegundos e envia apenas os 50 candidatos mais promissores para o processamento denso em memória.

2. Normalização Exponencial de Scores ($S_i = e^{-\lambda_i D_i}$)

- **Descrição Detalhada:**
  As distâncias brutas computadas para cada descritor (D_{HOG},

D_{LBP}, D_{PCA}, D_{Geom}) possuem magnitudes e escalas completamente diferentes (ex: Manhattan do LBP varia de 0 a 2000, enquanto a Euclidiana do PCA varia de 0 a 15). Cada distância bruta é convertida em um score de similaridade delimitado estritamente no intervalo $[0.0, 1.0]$ através da função de decaimento exponencial:
$$S_i = e^{-\lambda_i \cdot D_i}$$

- **Motivação Técnica:**
  Garante **homogeneidade e alinhamento de escala estatística**.
  Não é possível somar ou ponderar diretamente Grandezas numéricas em escalas diferentes. A função exponencial mapeia a distância de modo que uma distância zero ($D_i = 0$, identidade perfeita) resulte no score máximo 1.0, enquanto distâncias infinitas tendem a 0.0. O parâmetro λ_i serve para calibrar a taxa de decaimento específica de cada descritor, fazendo com que um score de 0.80 no LBP represente o mesmo nível de certeza estatística que um score de 0.80 no HOG.

3. Ponderação dos Descritores ($w_i \cdot S_i$)

- **Descrição Detalhada:**
  Atribui-se um peso relativo de relevância (w_i) para cada uma das técnicas, respeitando a restrição de normalização onde a soma de todos os pesos é igual a 1 ($\sum w_i = 1.0$):
  - $\text{Peso HOG } (w_{\text{HOG}}) = 0.35$ (Estrutura e Forma)
  - $\text{Peso LBP } (w_{\text{LBP}}) = 0.35$ (Textura de Pele)
  - $\text{Peso PCA } (w_{\text{PCA}}) = 0.15$ (Estrutura Holística Global)
  - $\text{Peso Geométrico } (w_{\text{Geom}}) = 0.15$ (Métricas Antropométricas)
- **Motivação Técnica:**
  Garante **resiliência por ortogonalidade e especialização**.
  O HOG e o LBP recebem os maiores pesos (70% da nota combinada) por serem descritores locais de altíssima discriminabilidade. O PCA e o Geométrico atuam como pesos complementares (30%), fornecendo validação estrutural ampla. Essa distribuição impede que variações pontuais na textura da pele (como uma espinha ou cicatriz recente) destruam o match, ao mesmo tempo que prioriza as características mais confiáveis do rosto.

4. Cláusula de Veto Ponderado (Mecanismo de Segurança Rígido)

- **Descrição Detalhada:**
  Antes de realizar a soma final dos scores, o backend Java checa individualmente a pontuação não ponderada de cada uma das 4 técnicas. Se **qualquer um** dos scores for menor que o limiar de veto ($T_{\text{veto}} = 0.40$), o candidato é **imediatamente rejeitado**, ignorando a média total:
  $$\text{Se } (S_{\text{HOG}} < 0.40 \text{ OU } S_{\text{LBP}} < 0.40 \text{ OU } S_{\text{PCA}} < 0.40 \text{ OU } S_{\text{Geom}} < 0.40) \longrightarrow \textbf{VETO (MATCH INVALIDADO)}$$

- **Motivação Técnica:**
  Garante a **eliminação do Falso Aceite (FAR) por mascaramento de média**.
  Sem a cláusula de veto, um impostor com formato de rosto e crânio idênticos ao cadastrado poderia atingir scores de HOG, PCA e Geométrico altíssimos (ex: $0.95, 0.90, 0.90$). Mesmo que o LBP (textura) acusasse um score baixíssimo (ex: 0.20, indicando que é outra pessoa), a média ponderada simples resultaria em 0.785, liberando o acesso. O veto atua como uma **trava lógica ortogonal**: se a textura, a forma ou a geometria falhar gravemente de forma isolada, a decisão matemática assume que a pessoa não é a mesma.

5. Fusão dos Scores e Tomada de Decisão Final ($S_{\text{total}} \ge T_{\text{global}}$)

- **Descrição Detalhada:**
  Superadas as checagens de veto, o sistema realiza a fusão por média ponderada simples dos scores normalizados:
  $$S_{\text{total}} = (S_{\text{HOG}} \cdot 0.35) + (S_{\text{LBP}} \cdot 0.35) + (S_{\text{PCA}} \cdot 0.15) + (S_{\text{Geom}} \cdot 0.15)$$
  A decisão final de identidade confirmada é emitida se, e somente se, o score fundido atingir o limiar de decisão global pré-calibrado:
  $$\text{Decisão} = \begin{cases} \textbf{MATCH CONFIRMADO}, & \text{se } S_{\text{total}} \ge 0.78 \\ \textbf{REJEITADO / NÃO RECONHECIDO}, & \text{se } S_{\text{total}} < 0.78 \end{cases}$$
- **Motivação Técnica:**
  Garante um **ponto de decisão rigoroso, determinístico e 100% auditável**.
  O valor $S_{\text{total}} \ge 0.78$ foi calibrado via EER (Equal Error Rate) para atuar no equilíbrio perfeito entre usabilidade e segurança. Como o pipeline já garantiu a perfeição da imagem nas Etapas 1, 2 e 3, qualquer pontuação combinada acima deste limiar oferece garantia matemática de pertencimento à mesma pessoa. Por não envolver pesos aprendidos por caixas-pretas (redes neurais), a decisão pode ser desacoplada e explicada matematicamente em qualquer auditoria técnica.

Classificação e Perfil dos Serviços

Os serviços dividem-se em dois grandes perfis computacionais: **Full-Path** (exige processamento de imagem/pixels via BoofCV) e **Fast-Path** (exige apenas álgebra vetorial e SQL, com resposta rápida).

Serviço / Endpoint	Entrada ⟶ Saída	Perfil de Carga	Caso de Uso Principal
1. Validação de Foto	Foto $\rightarrow$ boolean / Erros	**Full-Path** (Etapas 1 e 2)	Feedback em tempo real no App durante a captura (ex: "Abra os olhos", "Melhore a luz").
2. Extração de Embeddings	Foto $\rightarrow$ 4 Vetores	**Full-Path** (Etapas 1 a 4)	Processamento em lote (*batch*) ou sistemas externos que apenas registram usuários.
3. Match Foto vs. Foto	Foto A + Foto B $\rightarrow$ Score/Match	**Full-Path** (Etapas 1 a 5 para ambas)	Validação documental pontual sem banco de dados (ex: Foto confiada vs. Selfie ao vivo).
4. Match 4 Vetores vs. 4 Vetores	4 Vetores A + 4 Vetores B $\rightarrow$ Score/Match	**Fast-Path** (Apenas Etapa 5 em RAM)	Verificação ultrarrápida ($< 0{,}5\text{ ms}$) quando os vetores já estão em memória/cache (Redis).
5. Match 4 Vetores vs. Foto	4 Vetores + Foto $\rightarrow$ Score/Match	**Full-Path** (Etapas 1 a 4 na foto + Etapa 5)	Login 1:1 ou bater ponto (compara a foto da câmera contra o vetor do

			usuário retido no banco).
6. Match uuid foto com embedding vs foto	uuid + Foto B $\rightarrow$ Score/Matc	**Full-Path** (Etapas 1 a 4 na foto + Etapa 5)	Login 1:1 ou bater ponto (compara a foto da câmera contra o vetor do usuário retido no banco).
7. Busca 1:N por Foto	Foto $\rightarrow$ Top N (menor que 50) Candidatos	**Full-Path** (Etapas 1 a 4 + HNSW no pgvector)	Reconhecimento em catracas ou acesso sem identificação prévia (digitar CPF).
8. Busca 1:N por 4 Vetores	4 Vetores $\rightarrow$ Top N (menor que 50) Candidatos	**Fast-Path** (Apenas HNSW no pgvector)	Consulta ou refinamento de buscas quando o vetor já foi extraído previamente.

Requisitos

1. Multi-tenancy (Isolamento por Cliente)

- **Isolamento Rígido de Dados (Database Multitenancy):**
  - Uso da estratégia de **Schema por Tenant** ou **Discriminator Column (tenant_id) com Row Level Security (RLS)** habilitado diretamente no PostgreSQL. O RLS garante a nível de kernel do banco que nenhuma consulta retorne vetores de outro cliente, mesmo em caso de erro no SQL.
- **Isolamento de Credenciais e Cotas:**
  - Autenticação da API via **OAuth2 / API Keys/ JWT** mapeadas obrigatoriamente para um tenant_id.
  - Definição de *Rate Limiting* (limite de requisições/segundo) individualizado por tenant usando extensão de *Throttling* no Quarkus.

2. Temporalidade e Descarte de Dados (Ciclo de Vida)

- **Princípio da Minimização de Retenção:**

    - **Imagens Brutas (S3 / Storage):** A imagem enviada para teste (selfie da catraca/app) devem gravadas para auditoria da execução do pipeline e **no S3**. Os embeddings devem ser gravaos no PostgreSQL.Ambos devem ser descartados conforme temporalidade pré-definida.
- **Política de Expiração e Purga Automática (*TTL - Time To Live*):**
    - **Storage (S3):** Configuração de *Lifecycle Rules* no bucket S3 para exclusão definitiva (*Hard Delete*) ou migração para classe fria após N dias configurados pelo tenant.
    - **PostgreSQL (pgvector):** Criação de coluna expires_at na tabela de embeddings. Um *Cron Job* em segundo plano (*Quarkus Scheduler*) executa limpezas periódicas.

- **Revogação Rápida / Direito ao Esquecimento:**
    - Endpoint dedicado (`DELETE /v1/tenants/{tenant_id}/users/{user_id}`) que executa a exclusão atômica (vetores no PostgreSQL + foto no S3) para conformidade legal (LGPD).

3. Segurança da Informação

- **Criptografia em Repouso (Encryption at Rest):**
    - **S3:** Uso de criptografia obrigatória no lado do servidor (**SSE-KMS**) para os arquivos de imagem confiaveis.
    - **PostgreSQL:** Criptografia das partições de disco do banco de dados (LUKS) e suporte a *Transparent Data Encryption* (TDE).
- **Criptografia em Trânsito (Encryption in Transit):**
    - Tráfego 100% criptografado com **TLS 1.3** obrigatório para todas as APIs REST e conexões internas com o PostgreSQL e S3.
- **Anonimização de Identificadores:**
    - O banco de dados do motor de reconhecimento facial não deve armazenar dados sensíveis diretos (como CPF, nome completo ou e-mail). A tabela armazena apenas tenant_id, user_external_id (UUID gerado pelo cliente) e os vetores numéricos.

4. Auditabilidade e Rastreabilidade (Trilha de Auditoria)

- **Imutabilidade dos Logs de Auditoria:**
    - Geração de eventos de auditoria enviados para um repositório append-only ou banco de dados configurado.
- **Detalhamento Técnico da Decisão Matemática (Explicabilidade):**
    - Para cada operação de match ou busca, o log de auditoria deve registrar a "fita de decisão" completa sem salvar a foto:
        - request_id (UUID único da requisição)
        - tenant_id

        - Valores dos filtros de qualidade e neutralidade (Etapas 1 e 2)
        - Scores individuais não ponderados ($S_{\text{HOG}}, S_{\text{LBP}}, S_{\text{PCA}}, S_{\text{Geom}}$)
        - Indicador de acionamento da cláusula de veto (se algum $S_i < 0{,}45$)
        - Score final fundido e decisão emitida (MATCH_CONFIRMED ou REJECTED)
        - Tempo de execução de cada etapa em milissegundos.

5. Bilhetagem e Volumetria (Metering)

- **Métricas de Consumo por Tenant:**
    - Coleta e agregação de dados em tempo real utilizado para medir o uso de recursos por cliente:
        - Total de requisições por serviço (Serviços 1 a 7) em um período.
        - Contagem total de embeddings ativos armazenados na base por tenant.
        - Consumo de armazenamento em bytes no S3 por tenant.
- **Registro de Cobrança (Usage-based Billing):**
    - Envio de eventos de consumo para uma tabela de bilhetagem ou barramento de mensageria ao final de cada requisição bem-sucedida

Expectativa de Acurácia

O arcabouço projetado — fundamentado em um *pipeline* determinístico de 5 etapas (Qualidade de Ambiente, Neutralidade Facial, Alinhamento Afim, Extração Ortogonal e Fusão Ponderada com Veto) — apresenta uma expectativa de acurácia calibrada na faixa de **97% a 98% em ambientes controlados**, mantendo uma Taxa de Falsos Aceites (FAR) inferior a **0,1%** sob os limiares operacionais padronizados ($S_{\text{total}} \ge 0{,}78$ e $T_{\text{veto}} = 0{,}40$).

Essa alta taxa de assertividade sem o uso de Inteligência Artificial ou aprendizado de máquina apoia-se em três pilares determinísticos:

1. **Rejeição Ativa na Origem (*Garbage In, Garbage Out*):** A eliminação prévia de capturas com desfoque, iluminação assimétrica, desvios de pose 3D (Yaw), pálpebras fechadas e expressões faciais garante que 100% das imagens processadas pelos extratores estejam geometricamente e opcionalmente perfeitas.
2. **Ortogonalidade de Descritores:** A combinação de quatro visões matemáticas distintas — formato e gradientes (HOG), textura de pele (LBP), estrutura holística (PCA) e razões antropométricas (Geométrico) — garante que a limitação pontual de um método seja compensada pelos demais.
3. **Mecanismo de Veto Rígido:** A exigência de concordância entre os quatro vetores impede que a média ponderada seja mascarada por similaridades parciais, blindando o sistema contra falsos positivos.

Limitações em Relação ao Estado da Arte (Deep Learning / ArcFace)

Embora a abordagem atinja o limite máximo da computação visual clássica, existe uma lacuna de **1,5% a 3% de acurácia** em relação ao estado da arte em aprendizado profundo (redes neurais convolucionais profundas como ArcFace/CosFace, que superam **99,8%** no *benchmark* LFW).

Essa limitação ocorre devido às barreiras matemáticas e estruturais inerentes aos algoritmos determinísticos:

- **Incapacidade de Abstração Não Linear:** Métodos estatísticos e algébricos dependem de correspondências diretas na intensidade de pixels e nos gradientes locais. Redes neurais profundas aprendem representações abstratas e não lineares em manifolds de alta dimensão, conseguindo abstrair ruídos pesados e variações extremas.
- **Sensibilidade a Alterações Intra-classe Severas:** Mudanças anatômicas duradouras ou severas — como o envelhecimento ao longo de anos, variações drásticas de peso, cirurgias plásticas, crescimento de barba densa ou uso de maquiagem corretiva — alteram permanentemente os histogramas de LBP e HOG. O Deep Learning aprende a ignorar essas superfícies focando em invariantes profundas.
- **Densidade e Separatividade em Grandes Bases:** À medida que o banco de dados escala para centenas de milhares ou milhões de usuários, a densidade do espaço vetorial clássico gera sobreposição (*overlap*) de vetores entre indivíduos diferentes que possuem formatos de rosto parecidos. Modelos de aprendizagem profunda utilizam funções de perda angulares (*Margin Loss*) que forçam uma separação hiperesférica rigorosa, permitindo buscas em bases massivas sem perda de precisão.
- **Resistência a Ataques de Apresentação (Liveness / Anti-Spoofing):** O pipeline determinístico avalia a qualidade da imagem, mas não distingue nativamente uma face real tridimensional de uma fotografia impressa em alta resolução ou tela digital, exigindo hardware especializado (câmeras infravermelhas/profundidade) ou modelos de aprendizado adicionais para detectar tentativas de fraude por foto.

Ajuste Opcional (Decidir entre velocidade e acurácia)

Para priorizar a acurácia máxima, a adoção da resolução de **160x160 pixels** é a escolha exata: ela expande a densidade de pixels em relação ao padrão de 128x128, permitindo extrair o teto absoluto de precisão da visão computacional clássica. Necessário revisão no documento para redimensionar e também executar cálculos dos embeddings.

Reajuste do Arcabouço para Acurácia Máxima

1. Redimensionamento e Geometria (Etapa 3)

- **Dimensão:** Matriz estrita de **160x160 pixels** (25.600 pixels brutos).

- **Ganho:** O erro de quantização discreta no Vetor Geométrico cai de $2,0\%$ para apenas **$1,5\%$**, eliminando ambiguidades entre formatos de rosto muito semelhantes.

2. Quality Gate Elevado (Etapa 1)

- **Nova Regra IPD:** Elevação da Distância Interpupilar mínima de 80 para **IPD ≥ 100 pixels**.
- **Ganho:** Garante que a imagem capturada pelo sensor possui resolução óptica real suficiente, impedindo que a interpolação para 160x160 gere pixels inventados (*upsampling*).

3. Vetor HOG de Alta Resolução (Etapa 4)

- **Nova Estrutura:** Divisão em uma grade de 20×20 células de 8×8 pixels.
- **Banco de Dados:** Ajuste da coluna no PostgreSQL para vector(3249).
- **Ganho:** Capacidade de mapear detalhes finos, como a dobradiça palpebral, o filtro labial e curvaturas específicas do contorno mandibular.

4. Vetor LBP Multi-Escala (Etapa 4)

- **Nova Estrutura:** Extração dupla combinando raio pequeno ($R=1, P=8$) e raio médio ($R=2, P=16$).
- **Banco de Dados:** Ajuste da coluna no PostgreSQL para vector(512).
- **Ganho:** Mapeia simultaneamente a microtextura e a mesotextura da pele. A resolução de 160x160 absorve essa leitura dupla sem ser poluída por ruído de sensor.

5. Aperto dos Limiares de Decisão (Etapa 5)

- **Novo Limiar de Veto (T_{veto}):** Elevação de 0.40 para **0.45** (qualquer vetor individual com similaridade < 0.45 veta a combinação).
- **Novo Limiar Global (S_{total}):** Elevação de 0.78 para **0.82**.
- **Ganho:** Redução da Taxa de Falsos Aceites (FAR) para níveis residuais inferiores a **$0,01\%$**.

Impacto Esperado

Com o $IPD \ge 100\text{ pixels}$ e a matriz em 160x160, a acurácia global do arcabouço é empurrada para **~98,5% em ambientes controlados**, operando com nível de segurança institucional. O custo de processamento no Java/Quarkus sobe levemente.

Visão computacional clássica é considerada IA?

1. A Visão Acadêmica e Histórica (SIM)

Na taxonomia clássica da Ciência da Computação, a Visão Computacional sempre esteve sob o guarda-chuva da Inteligência Artificial. O objetivo macro da IA é fazer computadores realizarem tarefas que exigiriam inteligência humana — e "enxergar, reconhecer formas e medir proporções" se enquadra nessa definição teórica original, mesmo quando feito com matemática pura.

2. A Visão Moderna e Prática de Mercado (NÃO)

No mercado atual e na engenharia de software contemporânea, o termo "IA" virou sinônimo de **Machine Learning** e **Deep Learning** (redes neurais convolucionais, pesos treinados, aprendizado estatístico baseado em dados).

Nessa distinção prática:

- **Visão Computacional Clássica:** É categorizada como **Processamento Digital de Imagens (PDI)** ou **Geometria Computacional Determinística**. É baseada em código prescritivo (*rule-based*), onde o engenheiro escreve exatamente a equação matemática que o algoritmo deve executar (ex: equações de Sobel, SVD do PCA, histogramas do HOG).
- **IA / Deep Learning:** É baseada em "caixas-pretas" probabilísticas, onde o modelo aprende sozinho a extrair padrões através do ajuste de milhões de parâmetros conexos após processar bases massivas de imagens.

O que isso significa para o projeto?

No contexto do arcabouço em Quarkus/PostgreSQL, posicionar o sistema como **"livre de IA"** ou **"livre de Machine Learning"** é a abordagem corporativa e mercadológica correta:

- **Transparência e Explicabilidade:** garante-se a auditores que o sistema não possui decisões probabilísticas ou ocultas em matrizes de pesos treinados.
- **Inexistência de Viés de Treino (*Bias*):** O sistema não depende de um *dataset* prévio para "aprender" o que é um rosto, evitando desvios demográficos.
- **Determinismo:** Para os mesmos pixels de entrada, o código Java/BoofCV entregará **rigorosamente o mesmo resultado numérico** em 100% das execuções, algo que atende aos mais exigentes requisitos de governança e segurança da informação.